

# Projet à rendre Probabilités

---

Université de Thiès, UFR SES  
Département de Management des Organisations  
Master 1 Sciences de Données et Applications

Année universitaire 2019-2020  
Fatou Néné Diop

---

## 1 Loi faible des grands nombres et simulations sous Python

**Théorème 1.1 (Loi faible des grands nombres ou théorème de Khintchine)** *Soient des variables aléatoires  $Y_1, \dots, Y_n$  indépendantes telles que  $\mathbf{E}(Y_i) = m$  et  $\mathbf{V}(Y_i) = \sigma^2$ ,  $\forall i = 1, \dots, n$ . La moyenne empirique de ces variables converge en probabilité vers l'espérance  $m$  :*

$$\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow{\mathbf{P}} \mathbf{E}(Y_i) = m. \quad (1)$$

### Exercice 1:

On considère  $n$  variables aléatoires discrètes  $Z_1, \dots, Z_n$  indépendantes et identiquement distribuées (i.i.d.) telles que  $Z_i \sim \mathcal{P}(\lambda)$ . D'après les propriétés de la loi de Poisson, on sait que  $\mathbf{E}(Z_i) = \lambda$ . Par conséquent, d'après le théorème de Khintchine, on a :

$$\bar{Z}_n = \frac{1}{n} \sum_{i=1}^n Z_i \xrightarrow{\mathbf{P}} \lambda \quad (2)$$

Afin d'illustrer cette propriété, menons l'expérience suivante. On considère des variables aléatoires indépendantes et identiquement distribuées selon une loi uniforme  $Y_i \sim U_{[0,10]}$ ,  $\forall i = 1, \dots, n$ , avec  $\mathbf{E}(Y_i) = 5$ .

On applique la procédure suivante :

1. Grâce au logiciel Python, on tire des réalisations  $\{y_1, \dots, y_n\}$  des  $n$  variables  $\{Y_1, \dots, Y_n\}$ .
2. On calcule une réalisation de la moyenne empirique  $\bar{Y}_n$ . Cette réalisation est notée  $\bar{y}_n = n^{-1} \sum_{i=1}^n y_i$ .
3. On répète 5 000 fois les étapes 1 et 2. On obtient ainsi 5 000 réalisations de la variable  $\bar{Y}_n$ .
4. On construit l'histogramme de ces 5 000 réalisations.
5. On répète l'expérience pour différentes valeurs de la dimension  $n$  (taille d'échantillon). Prendre les valeurs  $n = 10$ ,  $n = 100$ ,  $n = 1000$  et  $n = 10000$ . Il convient de ne pas confondre ici la taille d'échantillon  $n$  (par exemple 3) et le nombre de répétitions (5 000).

Tracer les histogrammes des 10000 réalisations  $\bar{y}_n$  obtenues pour quatre valeurs de  $n$ , à savoir  $n = 10$ ,  $n = 100$ ,  $n = 1000$  et  $n = 10000$ .

Commenter les résultats obtenus.

## 2 Théorème central limite et simulations sous Python

**Théorème 2.1 (Théorème central limite, Lindeberg-Levy)** Soit  $Y_1, \dots, Y_n$  une séquence de variables aléatoires indépendantes et identiquement distribuées (i.i.d.) avec une espérance finie  $E(Y_i) = m$  et une variance finie  $\mathbf{V}(Y_i) = \sigma^2$ ,  $\forall i = 1, \dots, n$ . Alors la moyenne empirique  $\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i$  vérifie :

$$\sqrt{n} \left( \frac{\bar{Y}_n - m}{\sigma} \right) \xrightarrow{Loi} \mathcal{N}(0, 1). \quad (3)$$

### Exercice 2:

On considère des variables aléatoires indépendantes et identiquement distribuées selon une loi du khi-deux  $Y_i \sim \chi^2(2)$ ,  $\forall i = 1, \dots, n$ , avec  $\mathbf{E}(Y_i) = 2$  et  $\mathbf{V}(Y_i) = 4$ . On applique la procédure suivante :

1. Grâce au logiciel Python, on tire des réalisations  $\{y_1, \dots, y_n\}$  des  $n$  variables  $\{Y_1, \dots, Y_n\}$ .
2. On calcule une réalisation de la moyenne empirique  $\bar{Y}_n$ . Cette réalisation est notée  $\bar{y}_n = n^{-1} \sum_{i=1}^n y_i$ .
3. On considère la variable aléatoire transformée :

$$Z_n = \sqrt{n} \left( \frac{\bar{Y}_n - \mathbf{E}(Y_i)}{\sqrt{\mathbf{V}(Y_i)}} \right) = \sqrt{n} \left( \frac{\bar{Y}_n - 2}{2} \right) \quad (4)$$

À partir de la réalisation de la moyenne empirique  $\bar{y}_n$ , on calcule une réalisation de cette variable transformée comme  $z_n = \sqrt{n} (\bar{y}_n - 2) / 2$ .

4. On répète cette procédure 5 000 fois (étapes 1 à 3). On obtient alors 5 000 réalisations de la variable  $z_n$ .
5. On construit un histogramme de ces 5 000 réalisations et l'on compare cet histogramme à la densité d'une loi normale centrée réduite  $\mathcal{N}(0, 1)$ .

**Exercice 3:** *Théorème central limite appliqué au traitement de texte*

Le texte "LesMiserables1" est disponible sur le site (web [www.gutenberg.org](http://www.gutenberg.org)).

- Télécharger <https://r-stat-sc-donnees.github.io/LesMiserables1.txt>.
- Supprimer la ponctuation, les majuscules / minuscules et divisez le texte en jetons individuels (mots).
- Pour les mots (*un, et, le, il, est*) calcule leurs nombres respectifs au fur et à mesure que le livre progresse, exemple

$$n_{le}[i] = \sum_{j=1}^i \{w_j = le\}.$$

- Tracer les proportions  $n_{mot}[i]/i$  sur le document dans un seul graphique.
- Pourquoi ne pouvons-nous pas appliquer le théorème central limite (TCL) directement ?
- Que devons-nous faire sur le texte pour appliquer le TCL ?

```
import string
import urllib.request
x = urllib.request.urlopen('https://r-stat-sc-donnees.github.io/LesMiserables1.txt')
livre=str(x.read())
print(livre)

#Ajouter vos codes ici
```

**Définition 2.1** Soit  $X$  un vecteur aléatoire sur l'espace probabilisé  $(\Omega, \mathcal{A}, \mathbf{P})$  à valeurs dans  $\mathbb{R}^d$ . La loi image  $\mathbf{P}X^{-1}$  est appelée *distribution de la v.a.  $X$* , et est notée  $\mathbf{P}_X$ .

On appelle *fonction caractéristique de  $X$*  la fonction  $\Phi_X : \mathbb{R}^n \rightarrow \mathbb{C}$  définie par

$$\Phi_X(u) = \mathbf{E} [e^{i\langle u, X \rangle}] \quad \text{pour tout } u \in \mathbb{R}^d.$$

La fonction caractéristique dépend uniquement de la loi de  $X$  :

$$\Phi_X(u) = \int_{\mathbb{R}^n} e^{i\langle u, x \rangle} d\mathbf{P}_X(x),$$

et n'est rien d'autre que la transformée de Fourier de  $\mathbf{P}_X$  au point  $-u/2\pi$ .

**Exercice 4:** *Fonction caractéristique*

1. Pour un vecteur gaussien  $X$  de moyenne  $b$  et de matrice de variance  $V$ , montrer que

$$\Phi_X(u) = e^{\langle u, b \rangle - \frac{1}{2} \langle u, V u \rangle}.$$

2. Si  $\mathbf{P}_X$  est symétrique par rapport à l'origine, i.e.  $\mathbf{P}_X = \mathbf{P}_{-X}$ , montrer que  $\Phi_X$  est à valeurs réelles.
3. Pour une v.a. réelle, supposons que  $\mathbf{E}[|X|^p] < \infty$  pour un certain entier  $p \geq 1$ . Montrer que  $\Phi_X$  est  $p$  fois dérivable et

$$\Phi_X^{(k)}(0) = i^k \mathbf{E}[X^k], \quad \text{pour } k = 1, \dots, p.$$